

基於深度估計與自適應融合之影像去霧研究

¹Chin-Chieh Hsiao (蕭晉杰), and ^{1,2,*}Cheng-Shu You (游承書)

¹ Master's Program of Data Science,
Feng Chia University, Taichung City, Taiwan,

² Department of Applied Mathematics,
Feng Chia University, Taichung City, Taiwan,
E-mail: csyou@fcu.edu.tw

摘要

本文提出一種結合深度估計與多尺度融合之單張影像去霧方法。該方法首先採用 U-Net 網路估計場景深度圖，並透過調整散射係數導出多層級的傳輸圖，進而結合大氣散射模型重建去霧影像。為進一步提升去霧品質，我們引入多尺度金字塔融合策略以強化去霧效果。此外，所提出的訓練框架結合像素級監督與大氣散射模型之物理約束的損失函數，可同時提供結構一致性與物理合理性之學習。實驗結果顯示，本方法在應對多變的霧霾濃度時展現出高度的穩定性。特別是在影像對比度提升與細節還原方面，其綜合效能表現突出，與多種現有方法相比，具備顯著的競爭力。

關鍵字：影像去霧, 影像融合, 深度學習, 電腦視覺。

1. 引言

在自然環境中，大氣中的懸浮微粒與水汽所引起的光線散射會形成霧氣，導致影像對比度與清晰度顯著降低 [1]，進而影響視覺系統的判斷。此問題對自動駕駛、監控與遙測應用皆構成挑戰，並已成為電腦視覺領域中一項重要的研究課題。

從有霧的影像復原清晰影像本質上具有挑戰性，傳統方法多利用各種先驗訊息估計相關參數來解決，如暗通道先驗(Dark Channel Prior, DCP) [6] 與顏色衰減先驗(Color Attenuation Prior, CAP) [3] 依賴場景假設來估計傳輸圖並復原影像，然而，此類方法在複雜場景下容易產生不自然結果。近年來，隨著深度學習技術發展，越來越多研究轉向採用資料驅動模型，嘗試直接學習去霧映射 [4]，儘管能自動提取特徵，卻可能忽略大氣散射物理規律，進而產生不符合物理真實性的結果。

本研究提出一種混合式去霧架構，結合深度學習與物理模型，針對單張有霧影像進行去霧處理。具體而言，我們首先採用 U-Net 網路建立深度估計模

型，結合像素級監督以及物理重建的損失函數來訓練深度圖。基於深度訊息，我們動態調整散射係數以產生三張傳輸圖(Transmission Maps)，繼而利用大氣散射模型(Atmospheric Scattering Model)重建對應的去霧影像。最後，使用多尺度拉普拉斯金字塔融合技術 [5]，自適應選取各影像中最佳去霧區域進行融合，以提升去霧的穩定性與視覺品質。此方法兼具神經網路特徵提取能力與物理約束性，使其能夠自適應不同濃霧與景深條件。

我們研究的貢獻總結如下：

- 提出一種具物理與學習特性之混合去霧架構，相比傳統方法提升了對高亮區域的穩健性以及強化結果的可解釋性。
- 提出了一組結合像素級監督與物理重建約束的損失函數，有效解決了深度估計中的邊緣模糊問題，顯著強化了場景的結構細節學習。

2. 相關研究

傳統去霧方法大多基於大氣散射模型 [1]，其描述有霧影像是由直接衰減項與空氣光所組成，定義如下：

$$I(x) = J(x)t(x) + A(1 - t(x)), \quad (1)$$

其中 $I(x)$ 為有霧影像， $J(x)$ 為無霧影像， A 為大氣光(Atmosphere Light)， $t(x)$ 為傳輸圖(Transmission Map)，表示未受散射影響並成功到達相機的光線比例。在均勻大氣下， $t(x)$ 隨深度以指數衰減，其表示式如下：

$$t(x) = e^{-\beta \cdot d(x)}. \quad (2)$$

其中 $d(x)$ 為場景深度， β 為介質散射係數。在均勻大氣假設下， β 在整個場景中可視為一個常數。去霧關鍵在於準確估計傳輸圖與大氣光進而重建去霧影像。

He 等人 [6] 提出的暗通道先驗基於關鍵觀察：在無霧影像的局部區域中，至少存在一個顏色通道的像素強度接近零，據此先驗可推導傳輸圖與大氣




圖 1 混合式去霧方法整體流程架構圖

光，並透過公式(1)進行去霧處理。然而，該方法對於白色或低飽和區域敏感，易導致傳輸圖的估計偏差。Zhu 等人 [3] 提出顏色衰減先驗則利用亮度與飽和度的差異估計深度，進而推導出傳輸圖。但仍面臨相似問題。這些方法普遍依賴先驗假設，使其在複雜場景下的表現穩定性不足。為改善傳統方法之局限，Galdran [5] 提出基於多重曝光與拉普拉斯金字塔融合去霧方法，利用 Gamma 校正與 CLAHE 產生不同曝光影像，並以飽和度與對比度決定融合權重，透過金字塔融合實現去霧。其後 Zhu 等人 [7] 進一步提出將影像分解為全域層與細節層，分別計算融合權重，並引入飽和度補償強化視覺效果。整體流程不再依賴傳輸圖估計，避免了錯估問題。

近年來，深度學習技術亦被廣泛應用於去霧任務，Cai 等人 [4] 提出 DehazeNet，採用卷積神經網路估計傳輸圖，結合大氣散射模型還原清晰影像。Li 等人 [8] 提出 AOD-Net，將傳輸圖與大氣光整合為單一可學習參數，簡化推論流程。Song 等人 [9] 則基於 ViT 架構提出 DehazeFormer，結合 U-Net 與 Swin Transformer 優勢，透過殘差形式學習，並改良多項架構提升全局特徵提取與細部紋理的穩定性。

綜上所述，傳統方法雖具物理理論基礎但對先驗假設依賴性高；融合方法雖能避免誤估問題但缺乏物理依據；深度學習方法具強大特徵學習能力但可能產生違反物理真實性的結果。有鑑於此，本文提出一種混合式去霧架構，旨結合大氣散射模型的物理可解釋性與深度學習特徵提取能力，並透過多影像金字塔融合策略使其具備不同霧濃度條件下的自適應能力，進一步提升去霧穩定性。

3. 混合式去霧架構

本研究提出一種結合深度學習深度估計與多尺度金字塔融合的混合式去霧架構，如圖 1 所示。首先，利用 U-Net 網路對有霧影像進行深度圖 $d(x)$ 估計，

隨後，使用引導濾波(Guided Filter)對其邊緣結構進行細化，以確保邊緣輪廓與原始影像更為一致。接著，我們依據此深度圖 $d(x)$ 計算傳輸圖 $t(x)$ 。有鑑於單張 $t(x)$ 還原的去霧影像可能僅在局部區域表現良好，為達到全局良好去霧效果，我們透過實驗經驗設置三個散射係數 $\beta = 0.6$ 、 1.2 和 1.5 ，分別對應薄霧、中度霧、濃霧情境，產生不同程度的 $t(x)$ 並根據大氣散射模型復原三張不同程度的去霧影像，其中，大氣光 A 採用 DCP 方法 [6] 估計。最後，將上述三張不同程度的去霧影像與原始霧圖一同利用多尺度拉普拉斯金字塔技術 [5]，自適應挑選去霧效果較佳區域進行融合，進而最終融合去霧影像。其詳細介紹如下。

3.1. 深度估計

3.1.1. U-Net 神經網路

為達成估計深度並維持邊界輪廓的目標，本研究採用標準 U-Net 網路架構 [11] 作為實驗的骨幹模型(如圖 2 所示)，此外，進階變體如 Res-U-Net [23] 與 Attention U-Net [24] 亦具備相容性，可應用於本方法所建立之架構中。U-Net 可分為編碼器(Encoder)與解碼器(Decoder)兩部分，並透過跳躍連接(Skip Concatenate)有效地保留結構資訊，對於維持細節與輪廓訊息的完整性至關重要。本實驗輸入有霧影像解析度為 $224 \times 224 \times 3$ ，輸出單通道深度圖解析度為 $224 \times 224 \times 1$ 。

在具體實現方面，編碼器(如圖 2 左側)負責提取輸入影像特徵，首先透過兩層 3×3 卷積層進行特徵提取，接著以 2×2 最大池化下採樣壓縮空間並擴大感受野，同時使用 Dropout 防止過擬合。上述流程重複四次後特徵圖尺寸逐漸減半、通道數遞增，逐漸學習更高階的特徵。最底層潛空間(Latent Space)再經兩層 3×3 卷積層進一步提取深層特徵。解碼器(如圖 2 右側)負責重建影像，透過 2×2 轉置卷積(Transpose




圖 2 深度估計 U-Net 網路架構設計圖

Convolution)上採樣放大影像尺寸，並與編碼器中對應層次的特徵圖在通道維度上進行跳躍連接，補償多次池化造成的細節丟失，防止影像結構扭曲。連接後再經兩層 3×3 卷積層融合特徵並同樣使用 Dropout。上述上採樣與卷積操作重複四次後，影像恢復至原始尺寸。最後加入批次正規化 (Batch Normalization) 以穩定訓練過程，並使用 1×1 卷積輸出單通道深度圖。此外，所有卷積操作後均使用 ReLU 作為激活函數。

3.1.2. 損失函數

深度估計屬於密集預測 (Dense Prediction) 任務，需要對影像中每個像素點進行深度值的估計。我們觀察到若僅對深度圖採用傳統的像素級誤差 (如 L1 或 L2 損失) 來訓練，模型雖能學習整體深度分布，卻難以保持物體邊緣的連續性與結構細節，導致後續去霧結果產生人工瑕疵。為改善此問題，本研究提出基於大氣散射模型的物理約束項，該約束項利用估計深度圖將清晰影像重新霧化為有霧影像，並計算其與原始輸入霧圖之間的重建誤差。此設計強迫模型在學習深度時同時必須確保其預測結果符合光線在大氣中散射的物理規律，從而能生成邊緣輪廓更清晰、結構更合理的深度圖。

數學上，損失函數包含兩部分，首先計算估計深度 $\hat{d}(x)$ 與真實標籤 $d(x)$ 的 L2 誤差：

$$L_{depth} = \frac{1}{M \times N} \sum_{i=1}^M \sum_{j=1}^N \left(d(i,j) - \hat{d}(i,j) \right)^2, \quad (3)$$

此損失可視為資料項 (Data Term)，用來衡量深度的估計準確度。接著，根據大氣散射模型，使用估計深度 $\hat{d}(x)$ 、乾淨影像 $J(x)$ 與大氣光 A 還原有霧影像 $\hat{I}(x)$ ，並計算 $\hat{I}(x)$ 與原始霧圖 $I(x)$ 之 L2 誤差：

$$\hat{I}(i,j) = J(i,j)\hat{t}(i,j) + A(1 - \hat{t}(i,j)), \quad (4)$$

$$L_{hazy} = \frac{1}{M \times N} \sum_{i=1}^M \sum_{j=1}^N \left(I(i,j) - \hat{I}(i,j) \right)^2, \quad (5)$$

其中， $\hat{t}(i,j)$ 是透過估計深度 $\hat{d}(i,j)$ 根據公式 (2) 計算而得的估計傳輸圖。此部分相當於正則項




圖 3 多尺度拉普拉斯金字塔融合示意圖

(Regularization)，透過影像重建進一步約束深度圖。最終損失如下：

$$L_{total} = \theta_1 \cdot L_{depth} + \theta_2 \cdot L_{hazy}. \quad (6)$$

經實驗驗證，權重係數設置為 $\theta_1 = 1, \theta_2 = 0.5$ 能有效平衡深度估計與物理一致性。

3.2. 引導濾波器深度圖細化

引導濾波器是一種具邊緣保留特性的線性濾波器，可在平滑處理的同時有效保留影像結構 [14]。本研究以有霧影像之灰階作為引導圖，透過引導濾波提升深度圖的輪廓準確度。

引導濾波假設在每個局部區域內，輸出圖 q 與引導圖 I 存在線性關係。令 ω_k 為以像素 (i_k, j_k) 為中心、半徑為 r 的局部窗口，在此區域內可表示為：

$$q_{ij} = a_k I_{ij} + b_k, \quad \forall i, j \in \omega_k \quad (7)$$

其中 a_k 與 b_k 為該區域內固定係數。此式意即輸出圖 q 是引導圖 I 的線性變換。另一方面， q 也可視為輸入圖 p 去雜訊的結果，如公式 (8) 所示：

$$q_{ij} = p_{ij} - n_{ij}, \quad \forall i, j \in \omega_k \quad (8)$$

其中 n 為雜訊。因此，引導濾波希望在每個局部窗口中，以引導圖 I 所引導的線性模型近似輸入圖 p ，藉此最小化雜訊 n 同時達到平滑處理與邊緣保留的效果。為此，定義以下最小化目標函數以求解最佳 a_k 與 b_k ：

$$E_k(a_k, b_k) = \sum_{i,j \in \omega_k} \left((a_k I_{ij} + b_k - p_{ij})^2 + \varepsilon a_k^2 \right), \quad (9)$$

其中 ε 為正則化參數，防止 a_k 過大或除零。求解該目標函數可透過分別對 a_k 與 b_k 求偏導並令其為零得到：

$$a_k = \frac{\overline{p_k I_k} - \overline{p_k} \overline{I_k}}{\overline{I_k^2} - \overline{I_k}^2 + \varepsilon}, \quad (10)$$

$$b_k = \overline{p_k} - a_k \overline{I_k}, \quad (11)$$

其中 $\overline{p_k}$ 為局部窗口 ω_k 中 p 的均值。由於一個像素點可能同時屬於多個窗口，為整合重複結果，對窗口內所有 q_{ij} 取平均作為最終輸出：




圖 4 不同去霧方法在深度估計的結果比較。(a) 有霧影像；(b) DCP [6]；(c) CAP [3]；(d) DehazeNet [4]；(e) 本研究方法。

$$q_i = \frac{1}{|\omega_k|} \sum_{k: i \in \omega_k} (a_k I_i + b_k) = \bar{a}_i I_i + \bar{b}_i. \quad (12)$$

3.3. 多尺度拉普拉斯金字塔融合

多尺度拉普拉斯金字塔融合是一種基於影像金字塔理論的影像融合技術 [2]，旨在於不同解析度下分解並整合輸入影像，能保留各來源影像中的重要細節與結構資訊。圖 3 展示金字塔融合架構的示意圖。

首先對每張輸入影像建立高斯金字塔：

$$G_k^i = DS(K_\sigma * G_k^{i-1}), \quad i = 2, 3, \dots, N \quad (13)$$

其中， G_k^i 表示第 k 張影像第 i 層高斯金字塔， K_σ 為高斯濾波器， $DS(\cdot)$ 為下採樣運算。由於下採樣易導致影像出現不連續性，因此使用高斯濾波去除高頻資訊，保留大區域變化，能使縮小後影像更平滑自然。接著，建立拉普拉斯金字塔：

$$L_k^i = G_k^i - (K_\sigma * US(G_k^{i+1})), \quad i = 1, 2, \dots, N-1 \quad (14)$$

其中， L_k^i 表示第 k 張影像第 i 層拉普拉斯金字塔， $US(\cdot)$ 表示上採樣操作。此過程將上採樣後的影像與當前層相減得到每層影像的高頻訊息。為了緩解上採樣造成鋸齒狀邊界與出現雜訊，故對上採樣前先進行高斯濾波平滑處理。此外，最高層無可用以計算差分的影像，故定義 $L_k^N = G_k^N$ 。

完成金字塔建構後，需對原始解析度影像計算融合權重。由於霧氣會顯著降低影像對比度與飽和度，特別是遠處區域導致影像模糊與失真。因此，去霧效果良好的區域，其對比度與飽和度通常較高。為反映上述視覺品質，我們權重設計考量影像




圖 5 不同損失函數在深度估計的結果比較。(a) 有霧影像；(b) 使用 L_{depth} 之深度圖；(c) 使用 L_{total} 之深度圖。

的對比度 C_k 和飽和度 S_k ，數學上，其權重表示如下 [5]：

$$W_k(x) = C_k(x) \cdot S_k(x), \quad (15)$$

其中，對比度 C_k 以二階導數後的絕對值計算：

$$C_k(x) = \left| \frac{\partial^2 G_k}{\partial x^2}(x, y) + \frac{\partial^2 G_k}{\partial y^2}(x, y) \right|, \quad (16)$$

而飽和度 S_k 則以 RGB 三通道像素標準差計算：

$$S_k(x) = \sqrt{\frac{1}{3} \sum_{c \in \{R, G, B\}} (G_k^c(x) - \overline{G_k}(x))^2}, \quad (17)$$




圖 6 比較各方法之去霧效果。(a) 有霧影像；(b) DCP [6]；(c) CAP [3]；(d) AMEF-2018 [5]；(e) AMEF-2021 [7]；(f) DehazeNet [4]；(g) AOD-Net [8]；(h) DehazeFormer [9]；(i) UBRFC (outdoor) [10]；(j) 本研究去霧方法。

其中， $\overline{G_k}(x)$ 表示 RGB 三通道像素平均。

對所有影像權重圖 W_k 逐像素歸一化後，我們建立對應的權重高斯金字塔：

$$W_k^i = \mathcal{DS}(K_\sigma * W_k^{i-1}), \quad i = 2, 3, \dots, N \quad (18)$$

接著，開始對每一層進行融合，產生融合影像 F^i ：

$$F^i = \sum_{k=1}^4 L_k^i \cdot W_k^i, \quad i = 1, 2, \dots, N \quad (19)$$

完成各層融合後，可獲得一組 N 層之融合金字塔 $F^1, F^2, F^3, \dots, F^N$ 。最終從最低解析度 F^N 開始，逐層上採樣並與上一層相加進行重建，重建過程如下：

$$R^{i-1} = F^{i-1} + (K_\sigma * \mathcal{US}(F^i)), \quad i = N \quad (20)$$

$$R^{i-1} = F^{i-1} + (K_\sigma * \mathcal{US}(R^i)), \quad i \neq N \quad (21)$$

其中 R^i 為第 i 層重建影像。此融合策略能有效結合低頻背景資訊並逐層添加高頻細節，消除各影像間的邊界斷層，使融合影像在邊界過渡更平滑自然。




圖 7 金字塔融合權重圖。圖(f)-(h)紅色標示處顯示飽和度與對比度自適應挑選之最佳區域。

4. 實驗結果與分析

本章將展示所提方法在影像去霧任務中的實驗成果，包含定性視覺化比較與定量評估指標。我們方法將與八種經典去霧方法進行比較，包括 DCP [6]、CAP [3]、AMEF-2018 [5]、AMEF-2021 [7]、DehazeNet [4]、AOD-Net [8]、DehazeFormer [9] 與

表 1 不同去霧方法在合成測試集上的評估指標比較

Methods	With ground truth			Without ground truth		
	PSNR $\uparrow$	SSIM $\uparrow$	CIEDE2000 $\downarrow$	FADE $\downarrow$	Information Entropy $\uparrow$	CEIQ $\uparrow$
DCP [6]	15.5100	0.7981	13.2976	0.4135 (1)	7.0134	3.2397
CAP [3]	19.5688	0.8657	8.0242	0.7977	7.0496	3.2763
AMEF-2018 [5]	16.8042	0.8508	11.9174	0.7727	7.1941	3.2871 (3)
AMEF-2021 [7]	16.6341	0.8400	11.7241	0.8159	7.1768	3.2791
DehazeNet [4]	20.0476 (2)	0.8826 (2)	7.4932 (2)	0.9418	7.1628	3.2731
AOD-Net [8]	18.0476	0.8635	9.1847	0.8565	7.0373	3.2479
DehazeFormer [9]	19.9007 (3)	0.8700 (3)	7.4191 (1)	0.6098 (2)	7.2296 (3)	3.2810
UBRFC (outdoor) [25]	16.7519	0.8419	12.3108	1.0194	7.3286 (1)	3.3517 (2)
Our method	20.5912 (1)	0.8950 (1)	7.7283 (3)	0.6795 (3)	7.2784 (2)	3.3543 (1)

UBRFC (outdoor) [10]，每種方法的參數都設定為作者建議的預設值。

4.1. 實驗設定

4.1.1. 訓練集建構

本實驗使用 Kaggle 公開資料集：Pexels 110k 512p JPEG(乾淨影像) [12] 和對應的 Pexels 110k 512p JPEG Depth(深度影像) [13]，本研究從中篩選出戶外風景作為訓練資料，但考量到若僅使用風景照，模型易將「白色」錯誤學習為遠方霧氣從而錯估深度，因此特地加入近景白色物體影像，強化模型辨識白色物體與霧氣的能力。最終篩選出共 1207 張對應的乾淨影像及深度影像。為配合模型實際輸入條件，將影像透過大氣散射模型合成有霧影像，詳細合成步驟如下：

步驟一：根據深度 $d(x)$ 、設定散射係數 $\beta = 1$ ，透過公式(2)計算 $t(x)$ 。

步驟二：隨機生成大氣光 $A \in [0.7, 1.0]$ ，將 $J(x)$ 、 $t(x)$ 、 A 透過公式(1)合成人造有霧影像 $I(x)$ 。

將生成的 $J(x)$ 、 $I(x)$ 、 $d(x)$ 與 A 保存作為訓練使用。進入訓練前，隨機切分為訓練集(81%)、驗證集(9%)與測試集(10%)，以利後續模型評估。

4.1.2. 訓練超參數

本實驗深度估計模型採用 Adam 優化器，固定學習率 0.0001，批次大小 32，訓練 500 個 epochs。為提升泛化能力，對訓練集使用隨機水平翻轉之資料增強。於 Windows11 上進行實驗，python 為 3.6.13，Tensorflow 為 2.1.0，GPU 為 NVIDIA TITAN RTX。

4.2. 深度估計結果與分析

我們在各種戶外真實霧天影像上進行測試，並與 DCP [6]、CAP [3] 與 DehazeNet [4] 等有使用深度估計的去霧方法比較。由於大部分深度估計方法於一

表 2 不同去霧方法在真實有霧影像上的評估指標比較

Methods	Without ground truth		
	FADE $\downarrow$	Information Entropy $\uparrow$	CEIQ $\uparrow$
DCP [6]	0.3909 (1)	6.8685	3.0886
CAP [3]	0.8219	6.9316	3.1488
AMEF-2018 [5]	0.7057	7.0081	3.1461
AMEF-2021 [7]	0.7225	7.0861	3.2217 (3)
DehazeNet [4]	0.8641	7.0332	3.2186
AOD-Net [8]	0.7045 (3)	6.9349	3.1658
DehazeFormer [9]	0.7826	7.1357 (3)	3.1990
UBRFC (outdoor) [25]	0.8993	7.3518 (1)	3.4011 (1)
Our method	0.5669 (2)	7.1678 (2)	3.2508 (2)

般戶外影像都能取得良好的估計結果，因此在視覺上難以對其進行排名。為了進行比較，我們在一些具有大面積白色或高亮區的具有挑戰影像上進行比較。圖 4 展示了四種使用深度估計的去霧方法，可觀察到 DCP [6]、CAP [3] 與 DehazeNet [4] 皆容易受到白色、高亮物體干擾而誤判深度(如圖 4 中綠色框標示處)，這是因為 DCP [6] 與 CAP [3] 這類估計方法強烈依賴先驗的有效性，當場景物體與大氣光相似時先驗將會失效。而 DehazeNet [4] 的網路設計其中一項為最大輸出單元(Maxout Unit)，Maxout 的多組線性映射取最大值的運作方式具備類似 DCP [6] 方法中「最小通道先驗」的效果，因此存在與 DCP [6] 類似的問題。相比之下，本方法的結果緩解了此問題，於高亮度區域仍能準確估計深度，使整體結果更平滑與連續性。

此外，為了探討損失函數設計對模型學習效果的影響，我們在一些具有較細小輪廓的影像上，比較了僅使用深度誤差的基本損失 L_{depth} 與所提出的組合損失 L_{total} 下的學習表現。圖 5 中藍色框標示處可觀察到，使用基本損失估計的深度圖雖能掌握整體深度趨勢，但在細部邊緣結構上糊模不清。而採用組合損失所估計之深度圖，在邊界區域的輪廓更為清晰，更準確地對應原始霧圖中的物體結構，顯示該組合損失對於維持場景結構具有顯著效益。

4.3. 去霧效果定性比較

本節考慮真實有霧影像進行測試。圖 6 展示各種去霧方法於多張影像的去霧效果。觀察結果顯示，DCP [6] 雖能有效去除霧氣，但過度去霧導致影像失真，在天空區域或含有白色物體的場景產生色偏。此外，在前後景明顯的場景中易出現邊緣光暈現象。CAP [3] 因色彩飽和度過高導致影像過暗，細節表現較弱且缺乏層次感，且較遠的霧氣無法去除。融合方法 AMEF-2018 [5] 與 AMEF-2021 [7] 雖具有較高色彩對比度，但容易過度增強影響影像自然感。深度學習方法 DehazeNet [4] 與 AOD-Net [8] 的去霧效果相對有限，對微小結構的還原能力不足，被霧氣遮蔽的物件仍顯得模糊。DehazeFormer [9] 去霧效果較不穩定，部分場景過暗，且幾乎沒有去霧效果。UBRFC [10] 部分場景去霧後亮度過度提高，反而使得遠景的霧氣更加明顯，未能達到理想的清晰化效果。相較之下，我們的方法展現出較為穩定且自然的去霧表現，有效去除遠近景的霧氣(如圖 6 中火車、白衣男人與山景)，並保留清晰的紋理細節(如圖 6 中稻草堆、叢林)，還原出真實自然的色調(如圖 6 中紅磚牆、空拍圖、奔跑的人)，不被白色物體干擾(如圖 6 中人像)，且影像亮度適中(如圖 6 中人群)，有效強化影像清晰度與立體感，呈現更自然的視覺效果。

為了更清楚呈現本方法所採用融合技術的運作過程，圖 7 展示金字塔融合過程中各影像所對應之融合權重，清楚呈現在不同區域選擇最佳去霧版本的重要性。四張待融合影像各自在不同區域展現較佳的去霧效果(如圖 7(b)、(c)、(d)中的紅色框標示處)，透過融合，不僅有效改善去霧不均勻之問題，亦提升去霧效果之穩定性。

4.4. 評估指標定量比較

本節將對所提方法與其他去霧方法進行定量比較，以評估其在結構還原、視覺品質、細節保持與霧氣消除等面向的綜合表現。我們採用下列評估指標作為量化依據。

有參考圖評估指標：峰值訊號與雜訊比(PSNR)：衡量重建影像與真實影像的品質差異，數值越高表示品質越佳。結構相似性指標(SSIM)：評估影像結構之相似程度，其值域介於 [0,1] 之間，越接近 1 表示與真解越相似。CIEDE2000 色差指標 [16]：評估在 Lab 色彩空間下之色差感知差異，數值越小表示色彩越接近。

無參考圖評估指標：霧感知密度評估器(FADE) [17]：評估影像中霧氣密度，數值越小表示影像越清晰。資訊熵(Entropy) [18]：評估影像內容之資訊豐富度，其值域介於 [0,8]，越高表示資訊越豐富。基於對比增強的品質指標(CEIQ) [19]：評估對比增強之品質，數值越高表示對比品質越佳。




圖 8 去霧前處理對 YOLO 物件偵測效能提升的比較。(a) 原始有霧影像辨識結果；(b) 本方法去霧後辨識結果。

表 1 基於測試集共 121 張影像，彙整本方法與其它八種方法的定量比較結果。從表中結果可見，我們的方法在 PSNR、SSIM 與 CEIQ 三項指標均取得第一，顯示其在整體品質、結構還原與對比度方面表現最佳。在色差指標 CIEDE2000 亦維持前三水準，與最佳方法 DehazeFormer [9] 僅有微幅差距。FADE 指標中，DCP [6] 雖因高強度去霧取得最低霧感分數，但常伴隨色偏與失真。本方法以融合機制有效處理不同濃度區域，兼顧畫面穩定性與視覺自然性，在 FADE 中亦名列前三。於細節與資訊豐富度方面，本方法能有效復原影像中的細節，於資訊熵指標同樣名列前三。此外，我們從多個資料集中 [20, 21] 蒐集共 100 張真實有霧影像，對其計算無真解評估指標，結果如表 2 所示。本方法依然展現穩定優勢，各項指標仍維持前三水準，顯示其在真實場景下具備良好穩定去霧能力。

4.5. 實際應用

為了驗證我們所提的去霧方法對電腦視覺辨識任務的實質效益，我們將其應用於先進的物件偵測方法 YOLO11x [15]。我們以 DAWN [20] 與 RTTS [22] 真實霧天影像為資料來源，將原始影像與去霧後影像分別輸入 YOLO 模型，觀察辨識效果差異，如圖 8 所示。實驗結果顯示去霧前處理能有效強化影像清晰度與物件輪廓，使 YOLO 成功偵測出原先未標註之目標，如卡車與交通號誌燈。此外，監控場景中也呈現相似結果，霧氣干擾造成物件遺漏，經去霧後可提升可視性與偵測準確性。

5. 總結

針對單張影像去霧方法常面臨的去霧效果不均、白色物體與高亮區誤判問題，提出一種結合深度學習

與多尺度拉普拉斯金字塔融合的混合式去霧架構，透過 U-Net 模型進行深度圖估計，並提出結合深度誤差與還原有霧影像誤差的損失函數，強化邊緣結構學習。並根據深度圖調整不同散射係數，重建多張去霧影像後利用拉普拉斯金字塔進行自適應融合，有效提升整體去霧品質。實驗結果顯示，所提的方法可估計出更平滑且準確的深度圖，顯著減少白色物體與高亮區誤判。此外，相較於端到端深度學習模型，我們透過估計深度圖將任務拆解，不僅有效降低了訓練難度，更具備物理解釋性。實驗亦觀察到，CNN 模型似乎更傾向學習霧氣濃度而非真實深度，然而此偏差反而有助於更準確辨識霧氣所在區域，進而提升去霧效果。

致謝

本研究獲得國家科學及技術委員會資助，計劃編號為 NSTC 113-2115-M-035-003。

REFERENCES

- [1] E. J. McCartney, *Optics of the Atmosphere: Scattering by Molecules and Particles*, Wiley, New York, 1976.
- [2] P. J. Burt and E. H. Adelson, "The Laplacian Pyramid as a Compact Image Code," *IEEE Trans. Commun.*, vol. 31, no. 4, pp. 532–540, 1983.
- [3] Q. Zhu, J. Mai, and L. Shao, "A Fast Single Image Haze Removal Algorithm Using Color Attenuation Prior," *IEEE Trans. Image Process.*, vol. 24, no. 11, pp. 3522–3533, 2015.
- [4] B. Cai, X. Xu, K. Jia, C. Qing, and D. Tao, "DehazeNet: An End-to-End System for Single Image Haze Removal," *IEEE Trans. Image Process.*, vol. 25, no. 11, pp. 5187–5198, 2016.
- [5] A. Galdran, "Image Dehazing by Artificial Multiple-Exposure Image Fusion," *Signal Processing*, vol. 149, pp. 135–147, 2018.
- [6] K. He, J. Sun, and X. Tang, "Single Image Haze Removal Using Dark Channel Prior," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 33, no. 12, pp. 2341–2353, 2010.
- [7] Z. Zhu, H. Wei, G. Hu, Y. Li, G. Qi, and N. Mazur, "A Novel Fast Single Image Dehazing Algorithm Based on Artificial Multiexposure Image Fusion," *IEEE Trans. Instrum. Meas.*, vol. 70, pp. 1–23, 2020.
- [8] B. Li, X. Peng, Z. Wang, J. Xu, and D. Feng, "AOD-Net: All-in-One Dehazing Network," in *Proc. IEEE Int. Conf. Comput. Vis.*, 2017, pp. 4770–4778.
- [9] Y. Song, Z. He, H. Qian, and X. Du, "Vision Transformers for Single Image Dehazing," *IEEE Trans. Image Process.*, vol. 32, pp. 1927–1941, 2023.
- [10] H. Sun, Y. Wen, H. Feng, Y. Zheng, Q. Mei, D. Ren, and M. Yu, "Unsupervised Bidirectional Contrastive Reconstruction and Adaptive Fine-Grained Channel Attention Networks for Image Dehazing," *Neural Networks*, vol. 176, p. 106314, 2024.
- [11] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," in *Proc. 18th Int. Conf. Med. Image Comput. Comput.-Assist. Intervent. (MICCAI)*, Munich, Germany, Oct. 2015, pp. 234–241.
- [12] Kaggle, "Pexels 110k 512p JPEG," <https://www.kaggle.com/datasets/innominate817/pexels-110k-512p-min-jpg/data>, Accessed March 3, 2025.
- [13] Kaggle, "Pexels 110k 512p JPEG Depth," <https://www.kaggle.com/datasets/innominate817/pexels-110k-512p-min-jpg-depth/data>, Accessed March 3, 2025.
- [14] K. He, J. Sun, and X. Tang, "Guided Image Filtering," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 35, no. 6, pp. 1397–1409, 2012.
- [15] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2016, pp. 779–788.
- [16] G. Sharma, W. Wu, and E. N. Dalal, "The CIEDE2000 Color-Difference Formula: Implementation Notes, Supplementary Test Data, and Mathematical Observations," *Color Res. Appl.*, vol. 30, no. 1, pp. 21–30, 2005.
- [17] L. K. Choi, J. You, and A. C. Bovik, "Referenceless Prediction of Perceptual Fog Density and Perceptual Image Defogging," *IEEE Trans. Image Process.*, vol. 24, no. 11, pp. 3888–3901, 2015.
- [18] C. E. Shannon, "A Mathematical Theory of Communication," *The Bell System Technical Journal*, vol. 27, no. 3, pp. 379–423, 1948.
- [19] J. Yan, J. Li, and X. Fu, "No-Reference Quality Assessment of Contrast-Distorted Images Using Contrast Enhancement," *arXiv preprint, arXiv:1904.08879*, 2019.
- [20] Mendeley Data, "DAWN Dataset," 2020. <https://data.mendeley.com/datasets/766ygrbt8y/3>, Accessed May 25, 2025.
- [21] University of Texas at Austin, "Referenceless Prediction of Perceptual Fog Density and Perceptual Image Defogging," https://live.ece.utexas.edu/research/fog/fade_defade.html, Accessed May 25, 2025.
- [22] Kaggle, "RTTS Dataset," <https://www.kaggle.com/datasets/tuncguyn/rtts-dataset>, Accessed May 25, 2025.
- [23] Z. Zhang, Q. Liu, and Y. Wang, "Road Extraction by Deep Residual U-Net," *IEEE Geoscience and Remote Sensing Letters*, vol. 15, no. 5, pp. 749–753, 2018.
- [24] O. Oktay, J. Schlemper, L. Le Folgoc, M. Lee, M. Heinrich, K. Misawa, K. Mori, S. McDonagh, N. Y. Hammerla, B. Kainz, B. Glocker, and D. Rueckert, "Attention U-Net: Learning where to look for the pancreas," *arXiv preprint arXiv:1804.03999*, 2018.